

DIPLOMADO EN CIENCIA DE DATOS

EduPath AI

Predice hoy. Impulsa el mañana.

Plataforma inteligente para la predicción del
rendimiento académico mediante
aprendizaje automático

Proyecto final

Alexia Abigail Martínez Gómez

Universidad Nacional Autónoma de México
Facultad de Estudios Superiores Acatlán

Agosto de 2026

Solución de ciencia de datos orientada a instituciones educativas para estimar el promedio académico esperado, identificar señales de atención y proponer acciones de seguimiento oportunas.

Índice

Resumen ejecutivo	1
1. Introducción	1
2. Planteamiento del problema	2
3. Objetivos	2
3.1. Objetivo general	2
3.2. Objetivos específicos	2
4. Estrategia de negocio	3
4.1. Compañía ficticia y propuesta de valor	3
4.2. Usuarios objetivo	3
4.3. Usabilidad del modelo	3
4.4. Accionables	3
5. Descripción de los datos	4
6. Análisis exploratorio de datos	5
6.1. Distribución del desempeño académico	5
6.2. Correlaciones y patrones principales	6
6.3. Apoyo familiar y tutorías	8
7. Procesamiento y preparación de datos	9
8. Modelación supervisada	10
8.1. Regresión Lineal	10
8.2. Random Forest	11
8.3. XGBoost	11
8.4. Red Neuronal	12
8.5. Comparación final	12
9. Resolución del problema mediante EduPath AI	12
9.1. Flujo de uso	12
9.2. Interpretación y límites	13

10.Evaluación general de la solución	14
11.Conclusiones	14
12.Trabajo futuro	14
A. Correspondencia con la rúbrica	15

Índice de figuras

1. Distribución de la clasificación académica.	5
2. Distribución del promedio académico (GPA).	6
3. Matriz de correlación entre variables.	7
4. Relaciones académicas con el promedio.	7
5. Relación de los apoyos con el desempeño académico.	8
6. Importancia relativa de las variables en el análisis predictivo.	9
7. Valores reales frente a valores predichos por la Regresión Lineal.	11
8. Pantalla de inicio de EduPath AI durante el desarrollo de la interfaz.	13
9. Resultado individual: promedio estimado, nivel de riesgo, fortalezas y plan de acción.	13

Índice de cuadros

1. Variables disponibles en el conjunto de datos.	4
2. Comparación de desempeño sobre el conjunto de prueba.	12
3. Ubicación de los criterios principales de evaluación.	15

Resumen ejecutivo

El bajo rendimiento académico suele identificarse cuando sus consecuencias ya son visibles: disminución del promedio, reprobación de asignaturas, pérdida de continuidad escolar o abandono. Este proyecto presenta **EduPath AI**, una plataforma de inteligencia educativa cuyo propósito es transformar información demográfica, académica, familiar y extracurricular en una estimación comprensible del rendimiento esperado de un estudiante. La solución integra un modelo de aprendizaje supervisado con una interfaz web desarrollada en Streamlit, de modo que docentes, tutores, orientadores y coordinadores puedan utilizarla sin conocimientos de programación.

El conjunto de datos analizado contiene **2,392 registros y 15 variables**. Después de excluir el identificador del estudiante y las variables de salida, se utilizaron 12 características predictoras: edad, género, grupo étnico, escolaridad parental, horas de estudio, ausencias, tutorías, apoyo familiar y participación en actividades extracurriculares, deportivas, musicales y de voluntariado. Se compararon cuatro enfoques de regresión: Regresión Lineal, Random Forest, XGBoost y una Red Neuronal. La Regresión Lineal obtuvo el mejor desempeño en el conjunto de prueba, con un error absoluto medio de **0.1553**, una raíz del error cuadrático medio de **0.1966** y un coeficiente de determinación de **0.9532**.

El análisis exploratorio mostró que el ausentismo constituye el factor con la relación negativa más fuerte respecto al promedio académico. También se observaron asociaciones positivas, aunque de menor magnitud, con las horas de estudio, las tutorías y el apoyo familiar. A partir de estos hallazgos, EduPath AI no se limita a mostrar una predicción: presenta fortalezas, señales de atención, un nivel operativo de riesgo y recomendaciones específicas para facilitar la intervención temprana. El resultado es una solución interpretable, usable y alineada con la toma de decisiones educativas basada en datos.

Palabras clave: rendimiento académico, aprendizaje supervisado, regresión, inteligencia educativa, Streamlit, intervención temprana.

1. Introducción

La ciencia de datos ofrece herramientas para convertir registros administrativos y académicos en conocimiento útil para la toma de decisiones. En el sector educativo, esta posibilidad es especialmente relevante porque una intervención oportuna puede modificar la trayectoria de un estudiante. Las instituciones generan información sobre asistencia, desempeño, hábitos de estudio y apoyos disponibles; sin embargo, estos datos suelen utilizarse de manera descriptiva y retrospectiva, cuando también podrían apoyar procesos preventivos.

EduPath AI surge como una propuesta para estimar el promedio académico esperado de estudiantes de educación media superior a partir de variables accesibles para una institución. El proyecto sigue un flujo completo de ciencia de datos: comprensión del problema, análisis exploratorio, preparación de datos, modelado supervisado, evaluación comparativa, selección de un modelo central y desarrollo de una interfaz de inferencia.

El enfoque se diseñó bajo dos principios. El primero es la **capacidad de generalización**: el modelo debe funcionar adecuadamente con datos no utilizados durante el entrenamiento. El segundo es la **usabilidad**: la predicción debe presentarse en un lenguaje entendible y acompañarse de información que facilite una acción concreta. De esta forma, la solución busca auxiliar, y no reemplazar, el criterio de docentes, tutores, orientadores y especialistas.

2. Planteamiento del problema

Las señales asociadas con un desempeño académico desfavorable no siempre se integran en una sola lectura. Un estudiante puede acumular ausencias, dedicar poco tiempo al estudio, carecer de tutorías y contar con poco acompañamiento familiar; no obstante, si cada variable se revisa de forma aislada, la institución puede detectar el riesgo hasta que el promedio ya ha disminuido.

El problema central se define como la necesidad de **estimar el rendimiento académico esperado a partir de información disponible y convertir dicha estimación en una herramienta de apoyo para la intervención temprana**. La solución debe responder tres preguntas:

1. ¿Qué promedio académico podría esperarse para un estudiante con un perfil determinado?
2. ¿Qué factores del perfil requieren atención o representan fortalezas?
3. ¿Qué acciones concretas puede considerar la institución después de obtener el resultado?

La relevancia del problema no se limita a mejorar una métrica académica. Una detección temprana puede ayudar a priorizar tutorías, investigar causas de ausentismo, fortalecer la comunicación con la familia y organizar seguimientos antes de que las dificultades se acumulen. Por ello, el valor de la solución depende tanto del desempeño predictivo como de la claridad con la que el resultado llega al usuario final.

3. Objetivos

3.1. Objetivo general

Desarrollar una plataforma de inteligencia educativa que utilice modelos de aprendizaje automático para estimar el promedio académico esperado de un estudiante y presentar señales de atención y recomendaciones que apoyen la toma de decisiones institucional.

3.2. Objetivos específicos

- Explorar la relación entre variables demográficas, familiares, académicas y extracurriculares con el promedio académico.
- Preparar un conjunto de datos reproducible, eliminando variables que no aportan información predictiva válida, como el identificador individual.
- Entrenar y comparar Regresión Lineal, Random Forest, XGBoost y una Red Neuronal mediante métricas consistentes.
- Seleccionar el modelo con mejor desempeño sobre datos no vistos y con mayor facilidad de interpretación.
- Implementar el flujo de inferencia en una interfaz web intuitiva.
- Traducir los resultados del modelo en fortalezas, alertas y accionables comprensibles para usuarios no técnicos.

4. Estrategia de negocio

4.1. Compañía ficticia y propuesta de valor

EduPath AI es una compañía ficticia de inteligencia educativa cuyo lema es «Predice hoy. Impulsa el mañana.». Su propuesta de valor consiste en ayudar a las instituciones a pasar de una gestión reactiva a una gestión preventiva. Mientras un sistema escolar tradicional registra calificaciones y asistencia históricas, EduPath AI integra estas señales para producir una estimación y orientar el seguimiento.

La solución puede ofrecerse bajo un esquema de software como servicio (SaaS), con planes diferenciados por número de estudiantes, funcionalidades de seguimiento y nivel de integración con sistemas escolares. La aplicación desarrollada en este proyecto representa un producto mínimo viable que demuestra el flujo principal: captura del perfil, predicción, interpretación y recomendación.

4.2. Usuarios objetivo

Los usuarios directos son:

- **Docentes y tutores:** requieren una lectura rápida para decidir a qué estudiantes dar seguimiento.
- **Orientadores y psicólogos educativos:** necesitan contextualizar la predicción con factores familiares y hábitos de estudio.
- **Coordinadores y directivos:** buscan priorizar recursos institucionales y observar tendencias agregadas.
- **Padres o tutores:** pueden recibir recomendaciones explicadas en lenguaje accesible, siempre mediadas por la institución.

El beneficiario final es el estudiante, quien podría recibir apoyo antes de que la dificultad académica se convierta en reprobación o abandono.

4.3. Usabilidad del modelo

La interfaz evita mostrar códigos internos como 0, 1, 2, 3 o nombres técnicos de columnas. En su lugar, utiliza etiquetas como «nivel de acompañamiento familiar», «horas de estudio por semana» y «promedio académico estimado». El resultado se organiza en cuatro componentes: estimación numérica, nivel operativo de riesgo, señales interpretables y plan de acción.

La clasificación de riesgo no es una probabilidad adicional producida por el modelo, sino una regla de negocio que facilita la lectura del promedio estimado. Esta distinción es importante para no presentar el coeficiente de determinación global como una supuesta confianza individual.

4.4. Accionables

Los accionables se fundamentan en el perfil capturado y en los patrones observados durante el análisis. Entre las acciones contempladas se encuentran:

- revisar las causas de un número elevado de ausencias;
- establecer seguimiento semanal o quincenal de asistencia;
- crear un plan de estudio con metas alcanzables;
- incorporar al estudiante a tutorías;
- fortalecer la comunicación entre la institución y la familia;
- mantener los apoyos actuales cuando el perfil sea favorable.

Estas recomendaciones no constituyen un diagnóstico ni una decisión automática. Su función es organizar la conversación y facilitar que el equipo educativo defina responsables, plazos e indicadores de avance.

5. Descripción de los datos

El archivo analizado contiene **2,392 observaciones y 15 variables**. La documentación disponible en el notebook describe un conjunto de datos orientado al estudio de factores que influyen en el desempeño académico. El archivo fue utilizado con fines académicos; antes de una implementación productiva deberá confirmarse su fuente primaria, licencia, periodo de levantamiento y representatividad institucional.

Cuadro 1: Variables disponibles en el conjunto de datos.

Variable	Descripción	Tipo funcional
StudentID	Identificador único del estudiante.	Identificador
Age	Edad entre 15 y 18 años.	Númerica discreta
Gender	Género codificado de forma binaria.	Categorica
Ethnicity	Grupo étnico codificado en cuatro categorías.	Categorica
ParentalEducation	Nivel educativo de padres o tutores.	Ordinal
StudyTimeWeekly	Horas de estudio por semana.	Númerica continua
Absences	Número de ausencias acumuladas.	Númerica discreta
Tutoring	Indica si el estudiante recibe tutorías.	Binaria
ParentalSupport	Nivel de acompañamiento familiar.	Ordinal
Extracurricular	Participación en actividades extracurriculares.	Binaria
Sports	Participación deportiva.	Binaria
Music	Participación en actividades musicales.	Binaria
Volunteering	Participación en voluntariado.	Binaria
GPA	Promedio académico en escala de 0 a 4.	Objetivo continuo
GradeClass	Clasificación académica derivada del desempeño.	Objetivo auxiliar

La revisión inicial confirmó que no existen valores faltantes en las 15 columnas. Todas las variables fueron importadas originalmente como `float64`, aunque varias representan categorías o indicadores binarios. Para mejorar su interpretación, dichas variables se convirtieron posteriormente a valores enteros.

La edad media es de 16.47 años, el tiempo promedio de estudio semanal es de 9.77 horas y el número medio de ausencias es de 14.54. El promedio académico medio es 1.91 sobre 4.00. Estas estadísticas sitúan el análisis en una población de educación media superior y muestran una variabilidad suficiente para modelar distintos perfiles.

6. Análisis exploratorio de datos

6.1. Distribución del desempeño académico

La variable `GradeClass` presenta un desbalance evidente: la categoría 4 concentra la mayor frecuencia, mientras que la categoría 0 es minoritaria (fig. 1). Aunque el problema final se formuló como regresión sobre el GPA y no como clasificación de `GradeClass`, esta distribución ayuda a comprender la composición del conjunto de datos.




Figura 1: Distribución de la clasificación académica.

La distribución del GPA cubre prácticamente toda la escala de 0 a 4, con mayor densidad en valores intermedios (fig. 2). No se observa una concentración extrema en un solo valor, lo cual permite entrenar un modelo de regresión con ejemplos de distintos niveles de desempeño.




Figura 2: Distribución del promedio académico (GPA).

6.2. Correlaciones y patrones principales

La matriz de correlación muestra dos relaciones sobresalientes: una correlación negativa muy fuerte entre las ausencias y el GPA ($r = -0.92$), y una correlación negativa entre `GradeClass` y GPA ($r = -0.78$), coherente con la forma en que se construye dicha clasificación. El GPA también presenta asociaciones positivas con apoyo familiar ($r = 0.19$), tiempo de estudio ($r = 0.18$) y tutorías ($r = 0.15$).




Figura 3: Matriz de correlación entre variables.

La relación entre horas de estudio y GPA es positiva, aunque con dispersión amplia (fig. 4a). Esto indica que estudiar más se asocia con un mejor rendimiento, pero no explica por sí solo todas las diferencias entre estudiantes.





Figura 4: Relaciones académicas con el promedio.

El patrón de ausencias es mucho más claro: conforme aumenta el número de faltas, el GPA disminuye

casi linealmente. Este resultado convierte al ausentismo en la principal señal de atención y justifica su prioridad dentro de las recomendaciones de EduPath AI.

6.3. Apoyo familiar y tutorías

Los diagramas de caja muestran un incremento gradual de la mediana del GPA conforme aumenta el apoyo familiar. De forma similar, los estudiantes que reciben tutorías presentan una mediana superior a quienes no cuentan con este apoyo.



(a) Apoyo familiar y GPA.

(b) Tutorías y GPA.

Figura 5: Relación de los apoyos con el desempeño académico.

La importancia de variables estimada durante el análisis confirma el predominio de las ausencias. El tiempo de estudio, el apoyo familiar y las tutorías aparecen a continuación, aunque con una contribución considerablemente menor (fig. 6).




Figura 6: Importancia relativa de las variables en el análisis predictivo.

7. Procesamiento y preparación de datos

El procesamiento se diseñó para conservar la mayor cantidad posible de información y evitar introducir transformaciones innecesarias. Los pasos principales fueron:

1. **Validación estructural:** se verificaron dimensiones, tipos de datos y presencia de valores faltantes.
2. **Conversión de tipos:** las variables categóricas y binarias se convirtieron de punto flotante a entero para facilitar la interpretación.
3. **Definición del objetivo:** se seleccionó GPA como variable continua a predecir.
4. **Eliminación de variables no predictivas:** StudentID se excluyó por ser un identificador arbitrario; GradeClass se excluyó porque está directamente relacionada con el desempeño y produciría fuga de información.
5. **Construcción de la matriz predictora:** se conservaron 12 variables independientes.
6. **División de datos:** el 80 % se destinó a entrenamiento (1,913 registros) y el 20 % a prueba (479 registros), utilizando una semilla fija para reproducibilidad.

No se aplicó imputación porque el conjunto no contiene datos faltantes. Tampoco se eliminaron valores extremos de forma automática, ya que los rangos observados corresponden a límites plausibles

establecidos por el propio dataset. Para la Red Neuronal se aplicó escalamiento de variables, mientras que los modelos basados en árboles no lo requirieron.

8. Modelación supervisada

El problema se formuló como una tarea de regresión. Se compararon cuatro modelos para equilibrar desempeño, complejidad e interpretabilidad. La evaluación se realizó con MAE, RMSE y R^2 .

- El **MAE** expresa el error absoluto promedio en unidades de GPA.
- El **RMSE** penaliza con mayor intensidad los errores grandes.
- El R^2 indica la proporción de variabilidad explicada por el modelo.

8.1. Regresión Lineal

La Regresión Lineal se utilizó como modelo base debido a su interpretabilidad y a su capacidad para cuantificar el efecto marginal de cada variable (James et al., 2021). El modelo obtuvo resultados prácticamente equivalentes en entrenamiento y prueba, lo que sugiere una alta estabilidad:

Entrenamiento

$$R^2 = 0.9541$$

Prueba

$$R^2 = 0.9532$$

En el conjunto de prueba, el MAE fue 0.1553 y el RMSE 0.1966. La cercanía entre los valores reales y predichos se observa en fig. 7; la mayoría de los puntos se concentra alrededor de la diagonal de predicción perfecta.




Figura 7: Valores reales frente a valores predichos por la Regresión Lineal.

Los coeficientes muestran contribuciones positivas para tutorías, actividades extracurriculares, deportes, música y apoyo familiar, mientras que las ausencias presentan el principal coeficiente negativo. Estos efectos deben interpretarse como asociaciones dentro del dataset y no como relaciones causales.

8.2. Random Forest

Random Forest combina múltiples árboles de decisión y promedia sus resultados para reducir la variabilidad (Breiman, 2001). En entrenamiento alcanzó $R^2 = 0.9906$, pero en prueba descendió a 0.9286. El aumento del MAE de 0.0713 a 0.1883 indica sobreajuste: el modelo aprendió con gran detalle el conjunto de entrenamiento, pero generalizó peor que la Regresión Lineal.

8.3. XGBoost

XGBoost construye árboles de forma secuencial, corrigiendo los errores de las iteraciones anteriores y utilizando regularización para controlar la complejidad (Chen & Guestrin, 2016). El modelo obtuvo $R^2 = 0.9684$ en entrenamiento y $R^2 = 0.9436$ en prueba, con MAE de 0.1698 y RMSE de 0.2159 en datos no vistos. Su desempeño fue alto, pero no superó la estabilidad ni el menor error de la Regresión Lineal.

8.4. Red Neuronal

La Red Neuronal empleó capas densas para aproximar relaciones no lineales entre las variables (Goodfellow et al., 2016). De acuerdo con la comparación final registrada en el notebook, alcanzó MAE de 0.1800, RMSE de 0.2290 y $R^2 = 0.9366$ en prueba. Aunque ofrece flexibilidad, su complejidad adicional no produjo una mejora para este conjunto de datos.

8.5. Comparación final

Cuadro 2: Comparación de desempeño sobre el conjunto de prueba.

Modelo	MAE	RMSE	R^2
Regresión Lineal	0.1553	0.1966	0.9532
XGBoost	0.1678	0.2138	0.9447
Red Neuronal	0.1800	0.2290	0.9366
Random Forest	0.1883	0.2429	0.9286

La Regresión Lineal fue seleccionada como modelo central porque obtuvo el menor error y el mayor R^2 en prueba. Además, la diferencia mínima entre entrenamiento y prueba demuestra una capacidad de generalización superior. Para una aplicación educativa, su interpretabilidad también es una ventaja: permite explicar la dirección de las asociaciones sin recurrir a un modelo de caja negra.

9. Resolución del problema mediante EduPath AI

La fase de inferencia se implementó en Streamlit, una biblioteca de Python orientada a la creación de aplicaciones de datos. La interfaz carga el modelo serializado, recibe 12 variables, crea un registro con el mismo orden utilizado durante el entrenamiento y genera el promedio académico estimado.

9.1. Flujo de uso

1. El usuario abre la plataforma y selecciona una nueva evaluación.
2. Captura información personal, hábitos académicos, apoyos y actividades.
3. La aplicación convierte las etiquetas comprensibles a los códigos requeridos por el modelo.
4. El modelo estima el promedio académico en escala de 0 a 4.
5. La plataforma presenta el nivel de riesgo, fortalezas, alertas, plan de acción y una interpretación personalizada mediante EduBot.
6. La evaluación se agrega al historial de la sesión.



Figura 8: Pantalla de inicio actualizada de EduPath AI.

La interfaz oculta términos técnicos innecesarios. Por ejemplo, utiliza «promedio académico estimado» en lugar de mostrar únicamente la sigla GPA, y presenta opciones como «alto», «moderado» o «muy alto» para el acompañamiento familiar.



Figura 9: Resultado individual con promedio estimado, nivel de riesgo, fortalezas y señales de atención.

9.2. Interpretación y límites

EduBot funciona como un asistente de interpretación basado en reglas transparentes. Su texto se adapta al nivel de riesgo, las ausencias, las horas de estudio, las fortalezas y las alertas detectadas. No se presenta como un diagnóstico automatizado. La interfaz incluye una advertencia explícita para recordar que el resultado debe complementarse con el criterio profesional y el contexto particular del

estudiante.

10. Evaluación general de la solución

La solución resuelve el problema planteado en tres niveles:

1. **Predicción:** estima el promedio académico esperado con un error absoluto promedio de aproximadamente 0.16 puntos en una escala de 0 a 4.
2. **Interpretación:** identifica patrones del perfil mediante reglas congruentes con el EDA, dando prioridad al ausentismo.
3. **Acción:** propone intervenciones concretas que pueden convertirse en tareas institucionales con responsables y fechas.

La solución es adecuada como prueba de concepto, pero su desempeño no debe generalizarse automáticamente a otras instituciones. El elevado R^2 puede reflejar relaciones particulares del conjunto de datos y requiere validación externa. También es indispensable evaluar equidad, privacidad y posibles sesgos antes de utilizar variables demográficas en decisiones reales.

11. Conclusiones

El proyecto demostró que es posible estimar el promedio académico a partir de variables accesibles y desplegar el resultado en una interfaz usable. El hallazgo más consistente es la fuerte relación negativa entre ausencias y GPA. Las horas de estudio, las tutorías y el apoyo familiar mostraron asociaciones positivas, lo que ofrece una base razonable para orientar acciones preventivas.

La comparación de cuatro modelos mostró que una mayor complejidad no garantiza un mejor desempeño. La Regresión Lineal superó a XGBoost, la Red Neuronal y Random Forest en el conjunto de prueba, con MAE de 0.1553, RMSE de 0.1966 y $R^2 = 0.9532$. Su estabilidad e interpretabilidad justifican su selección para EduPath AI.

La principal contribución del proyecto no es únicamente el modelo predictivo, sino la integración entre análisis, inferencia y usabilidad. EduPath AI transforma una predicción numérica en una lectura orientada a la toma de decisiones: presenta fortalezas, señales de atención y un plan de acción. De este modo, la ciencia de datos se convierte en una herramienta accesible para usuarios educativos no técnicos.

12. Trabajo futuro

Para evolucionar la prueba de concepto hacia una solución institucional se proponen los siguientes pasos:

- validar el modelo con datos reales de una o más instituciones y en diferentes periodos académicos;
- documentar y auditar la procedencia, licencia y representatividad del dataset;
- incorporar técnicas de explicabilidad local, como SHAP, después de validar su interpretación;

- evaluar sesgos y métricas de equidad entre grupos demográficos;
- implementar autenticación, control de acceso y protección de datos personales;
- desarrollar un dashboard agregado para directivos, evitando exponer información individual sensible;
- permitir la descarga de reportes y el seguimiento longitudinal del estudiante;
- desplegar la aplicación en la nube y establecer monitoreo de desempeño y deriva de datos.

Referencias

- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32. <https://doi.org/10.1023/A:1010933404324>
- Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785-794. <https://doi.org/10.1145/2939672.2939785>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2021). *An Introduction to Statistical Learning: With Applications in R* (2.^a ed.). Springer. <https://doi.org/10.1007/978-1-0716-1418-1>

A. Correspondencia con la rúbrica

Cuadro 3: Ubicación de los criterios principales de evaluación.

Criterio	Sección del documento
Introducción y abstract	Resumen ejecutivo e Introducción
Planteamiento del problema	Sección 2
Estrategia, usuarios y accionables	Sección 4
Descripción de datos	Sección 5
EDA	Sección 6
Procesamiento	Sección 7
Modelación y evaluación	Sección 8
Resolución del problema y usabilidad	Secciones 9 y 10
Conclusiones	Sección 11
Referencias APA	Bibliografía